

Relatório Técnico -- Sistema de Visão Computacional para Segurança do Trabalho

CEUB - Centro Universitário de Brasília

Pós-graduação em Engenharia de IA

Disciplina: Visão Computacional e Reconhecimento de Padrões (Prof. Romes Heriberto)

RA: 82600743

Aluno: André Luiz Lopes de Azevedo

Notebook Google Colab:

https://colab.research.google.com/drive/1rgTu0MIXdp5G9vLv50gLbI_9H61HY3yW?usp=sharing

Repositório: <https://github.com/andrella-br/visao-computacional-sistematizacao>

Vídeo de Apresentação:

<https://drive.google.com/file/d/1J6dCePB5x3PLGFHZLZDyKc9cJhC9-FBF/view?usp=sharing>

1. Problema e Cenário

Em canteiros de obra, o não uso de Equipamentos de Proteção Individual (EPI) -- capacete e colete de segurança -- é uma das principais causas de acidentes de trabalho. A fiscalização manual desse uso é cara, lenta e não escala para grandes obras ou múltiplas câmeras.

Este projeto constrói, de ponta a ponta, um sistema de visão computacional que:

1. **Detecta** o uso ou a ausência de EPIs (capacete, colete, máscara) em imagens de canteiro de obra, classificando também pessoas, cones de sinalização, máquinas e veículos;
2. **Segmenta** as pessoas presentes na cena (silhueta completa, não apenas caixa delimitadora);
3. Demonstra o funcionamento dos dois modelos em um **vídeo real** do cenário;
4. Vai além da demonstração visual e converte as detecções em um **relatório de conformidade** -- uma aplicação prática de auditoria automática de segurança.

O cenário (Segurança do Trabalho) é um dos exemplos citados no próprio enunciado da disciplina.

2. Dataset e Análise Exploratória (EDA)

2.1 Fontes de dados

Foram usadas duas fontes públicas, cada uma cobrindo uma das duas tarefas do projeto -- nenhuma anotação manual foi necessária:

Tarefa	Fonte	Licença	Volume total disponível	Subconjunto usado
Detecção (10 classes de EPI)	Construction Site Safety (Roboflow Universe, espelhado no Kaggle por snehilsanyal)	CC BY 4.0	2.801 imagens	350 imagens
Segmentação (classe person)	COCO 2017 (conjunto de validação, categoria person)	Licença padrão COCO (uso livre com atribuição)	2.693 imagens elegíveis (com máscara de pessoa)	300 imagens

As **10 classes de detecção** são: Hardhat, NO-Hardhat, Safety Vest, NO-Safety Vest, Mask, NO-Mask, Person, Safety Cone, machinery, vehicle. A **classe de segmentação** é person (silhueta completa).

Os subconjuntos foram selecionados por **amostragem estratificada com seed fixa (42)**, garantindo pelo menos 15 imagens por classe de EPI (evitando que classes raras como Safety Cone ou vehicle ficassem ausentes) e volume mínimo de 300 imagens por fonte.

2.2 Análise exploratória

Classe	Instâncias	% do total
Person	1246	25.4%
machinery	670	13.6%
NO-Safety Vest	525	10.7%
Safety Cone	493	10.0%
NO-Mask	426	8.7%
Safety Vest	410	8.3%
Hardhat	406	8.3%
NO-Hardhat	316	6.4%
Mask	214	4.4%
vehicle	207	4.2%

2.3 Splits reprodutíveis

Ambas as fontes foram divididas 70/20/10 (treino/validação/teste) com a mesma seed (42):

Fonte	Treino	Validação	Teste	Total
construction-site-safety	244	70	36	350
coco-person	210	60	30	300

3. Metodologia

Ambos os modelos foram treinados localmente, usando **Ultralytics YOLOv8** -- escolhido por já vir com suporte nativo a detecção e segmentação de instância na mesma família de modelos, simplificando a stack de ferramentas do projeto.

3.1 Detecção (Fase 2)

- **Modelo:** YOLOv8n (nano), pré-treinado no COCO, fine-tuning para as 10 classes de EPI.
- **Hiperparâmetros:** 30 épocas, `imgsz=640`, `batch=16`, otimizador `auto`, `seed=42`.
- **Tempo de treino:** ~59 minutos (CPU).

3.2 Segmentação (Fase 3)

- **Modelo:** YOLOv8n, pré-treinado no COCO, fine-tuning para a classe única `person`.
- **Conversão de dados:** os polígonos de anotação do COCO (formato JSON) foram convertidos para o formato YOLO-seg (labels `.txt` com coordenadas normalizadas).
- **Hiperparâmetros:** mesma configuração da Fase 2 (30 épocas, `imgsz=640`, `batch=16`, `seed=42`), para manter os dois modelos comparáveis.
- **Tempo de treino:** ~61 minutos (CPU).

4. Resultados

4.1 Validação

Métrica	Detector (EPI)	Segmentador -- caixa	Segmentador -- máscara
Precisão	0.608	0.738	0.697
Recall	0.464	0.509	0.507
mAP@0.5	0.490	0.561	0.559
mAP@0.5:0.95	0.278	0.333	0.288

4.2 Avaliação no conjunto de TESTE

Métrica	Detector (EPI)	Segmentador -- caixa	Segmentador -- máscara
Precisão	0.710	0.682	0.635
Recall	0.481	0.386	0.376

Métrica	Detector (EPI)	Segmentador -- caixa	Segmentador -- máscara
mAP@0.5	0.547	0.443	0.393
mAP@0.5:0.95	0.324	0.231	0.177
IoU médio (TP)	0.793 (n=316 caixas)	--	--

Matriz de confusão do detector (teste): as principais confusões observadas foram NO-Hardhat <-> Hardhat e NO-Mask <-> Mask -- esperado, já que essas classes descrevem o mesmo objeto em estados opostos (presente vs. ausente), e perceber a *ausência* de algo é uma tarefa mais difícil do que detectar sua presença.

4.3 Métricas por Classe

Classe	Precisão	Recall	mAP@0.5	mAP@0.5:0.95
machinery	0.665	0.667	0.714	0.519
Person	0.716	0.626	0.665	0.428
Mask	0.803	0.533	0.635	0.371
Hardhat	0.565	0.568	0.576	0.305
Safety Vest	0.604	0.411	0.476	0.254
NO-Safety Vest	0.602	0.387	0.483	0.255
vehicle	0.615	0.467	0.439	0.328
NO-Hardhat	0.644	0.455	0.443	0.180
Safety Cone	0.449	0.301	0.274	0.084
NO-Mask	0.416	0.223	0.195	0.060

5. Análise de Erros

1. Falso Negativo -- multidão com máscaras não detectada: .
2. Falso Negativo -- pessoas ao fundo de um grupo não contadas:
3. Falso Positivo -- caixas duplicadas e confusão de classe:
4. Falso Positivo -- pessoas contadas em excesso:

6. Comparação Caixas × Máscaras

- **Caixa (detector):** informa o *quê* está presente, mas é uma aproximação retangular grosseira da forma real do objeto.
- **Máscara (segmentador):** informa a *forma exata* da pessoa, mas não sabe nada sobre equipamento.

- **Conclusão:** os dois modelos são complementares. Um sistema completo de auditoria se beneficiaria de combinar as duas saídas (ex. usar a máscara para recortar a região de interesse e aplicar o detector de EPI só ali).
- **Limitação observada:** o segmentador, treinado apenas no COCO, gerou pelo menos um falso positivo de máscara sobre um pneu de máquina.

7. Aplicação Prática: Relatório de Conformidade de EPI

Resultado sobre o vídeo de 38.3s analisado:

Classe de violação	Eventos	Tempo total	% do vídeo
NO-Safety Vest	4	24.0s	62.8%
NO-Mask	7	12.4s	32.4%
NO-Hardhat	1	0.1s	0.3%

8. Demonstração em Vídeo

Vídeo de entrada: `video/input/video_final_canteiro_obra.mp4`.

Os dois modelos foram aplicados ao mesmo vídeo, gerando duas saídas anotadas:

- `video/output/deteccao_epi/` -- caixas de EPI sobrepostas em cada quadro.
- `video/output/segmentacao_pessoas/` -- máscaras de pessoa sobrepostas em cada quadro.

Rastreamento de Objetos (ByteTrack)

O detector foi rodado com **ByteTrack** (tracker embutido no Ultralytics) sobre o mesmo vídeo, atribuindo um **ID persistente** a cada objeto entre quadros -- não apenas uma detecção isolada por quadro.

Resultado:

Métrica	Valor
Objetos rastreados (tracks únicos)	99
Pessoas únicas (Person) no vídeo	20
NO-Hardhat -- objetos distintos	0
NO-Mask -- objetos distintos	16
NO-Safety Vest -- objetos distintos	26

Demo Interativa (Gradio)

A demo roda em uma sessão do Google Colab e gera um link público temporário.

9. Limitações e Próximos Passos

Limitações: - Dataset de treino pequeno (350 + 300 imagens) e treino curto (30 épocas em CPU). - Parte do dataset de detecção é composta por imagens-mosaico, o que pode ter afetado marginalmente o aprendizado de contexto espacial. - Segmentador nunca viu o domínio de canteiro de obra durante o treino (apenas COCO), gerando falsos positivos/negativos ao generalizar para esse domínio. - Cenas de multidões, grupos sobrepostos são o ponto fraco mais consistente do detector. - Conjuntos de teste pequenos tornam as métricas de teste sensíveis à composição específica das imagens.

Próximos passos (fora do escopo desta entrega): - Aplicar técnicas de balanceamento para as classes minoritárias (`vehicle` , `Mask` , `Safety Cone`). - Aumentar o limiar de confiança e a duração mínima de evento no relatório de conformidade, para reduzir ruído de falsos positivos pontuais.

10. Referências e Fontes de Dados

- **Construction Site Safety Image Dataset (Roboflow)** -- Roboflow Universe, espelhado no Kaggle por `snehilsanyal`. CC BY 4.0.
<https://www.kaggle.com/datasets/snehilsanyal/construction-site-safety-image-dataset-roboflow>
- **COCO 2017 (Common Objects in Context)** -- Lin et al., 2014. Licença padrão COCO.
<https://cocodataset.org/>
- **Vídeos de demonstração** -- Pexels (Pexels License). Ver `video/input/README.md` para os 3 links individuais.
- **Ultralytics YOLOv8** -- framework usado para detecção e segmentação. <https://docs.ultralytics.com/>